Slovenská technická univerzita v Bratislave

Fakulta informatiky a informačných technológií

# Zadanie 4a – klasifikácia

## Dokumentácia

Peter Smreček

AIS ID: 103130

E-mail: xsmrecek@stuba.sk

Predmet: UI

Deň a čas cvičenia: Utorok 16:00

Semester: ZS 20/21

Ročník: 2.

# Obsah

# 1. Zadanie

V 2D priestore so súradnicami X a Y v intervaloch od -5000 do +5000 sa nachádzajú body patriace 4 triedam. Na začiatku je v priestore 5 bodov z každej triedy, teda dokopy 20 bodov.

Úlohou je naprogramovať klasifikátor novo vkladaných bodov, ktorý priradí bodu triedu a vloží ho do 2D poľa. Postupne sa generuje 5000 bodov z každej triedy a vkladajú sa v poradí, že nikdy po sebe nenasledujú 2 body rovnakej triedy. Návratovú hodnotu klasifikátora porovnávame s pôvodnou triedou, s akou bol bod vygenerovaný.

Klasifikátor používa kNN algoritmus, pričom parameter k bude 1, 3, 7 alebo 15 a pôvodná vygenerovaná sada 20000 bodov bude pre každý experiment rovnaká.

Prázdne miesta v 2D ploche vyfarbíme celú podľa klasifikátora.

# 2. Opis algoritmu

Program som implementoval v programovacom jazyku Python s použitím štandardných balíkov a s prevzatým kódom implementácie KD stromu, ktorý sa používa na hľadanie k susedov pri finálnom vyfarbovaní celej plochy.

## 2.1. Reprezentácia údajov problému

Plochu reprezentujem maticou o veľkosti 10001 x 10001 bodov. Matica obsahuje na každom políčku číslo z rozsahu 0-4. 0 symbolizuje, že daný bod je biely, 1 symbolizuje, že je červený, 2 zelený, 3 modrý a 4 fialový. Do matice je na začiatku vložených 20 bodov daných zadaním.

## 2.2. Generovanie nových bodov

Postupne generujem 4 polia o veľkosti 5000 bodov každé. Tieto polia následne spájam do jedného poľa o veľkosti 20000 súradníc s tým, že súradnice sa v ňom striedajú v poradí červená, zelená, modrá, fialová. Všetky súradnice sú jedinečné.

## 2.3. Klasifikácia a pridanie nových bodov do plochy

Každý z 20000 vygenerovaných bodov je vložený do plochy funkciou `vytvor_testovaciu_sadu`. V tejto funkcií je každý bod klasifikovaný funkciou

`klasifikator_testovacich_bodov`, ktorá vráti triedu novo vkladaného bodu na základe najpočetnejšej farby z farieb `k` bodov v jeho okolí. Následne sa vyhodnotí, či sa klasifikátorom určená trieda zhoduje s triedou určenou pri generovaní tohto bodu. Klasifikácia prebieha bruteforce hľadaním najbližších bodov.

### 2.4. Klasifikácia celej plochy

Pri klasifikácií celej plochy sa používa funkcia `klasifikator_zvysnych_bodov`, ktorá na hľadanie `k` najbližších susedov nepoužíva bruteforce metódu, ale prevzatú implementáciu KD stromu. Implementáciu KD stromu som prevzal z https://github.com/Vectorized/Python-KD-Tree/blob/master/kdtree.py.

Táto funkcia je volaná funkciou `vyfarbi_mapu`, ktorá ju volá pre každý v poradí niekoľký bod ktorý je zadaný argumentom. Nevyfarbuje sa teda matica o veľkosti 10001 x 10001 bodov, ale napríklad iba matica o veľkosti 400 x 400 bodov, ak sa vyfarbuje len každý 25. bod v poradí.

Obe klasifikácie používajú vlastnú funkciu pre výpočet euklidovskej vzdialenosti.

### 2.5. Vizualizácia

Na vizualizáciu používam 2 rôzne funkcie. Pre vizualizáciu poľa vložených a oklasifikovaných súradníc používam funkciu `vizualizuj_pole`, ktorá vytvorí plochu jednotlivých bodov.

Pre vizualizáciu celej ofarbenej matice používam funkciu `vizualizuj_maticu`, ktorá zoberie ako vstupný argument maticu, 2D pole kde na každom indexe sa nachádza číslo 0-4, čo symbolizuje farbu daného políčka.

Funkcie podľa vstupného argumentu buď obrázok ukážu, alebo uložia. Obrázok je označený dátumom a časom vytvorenia s charakteristikou testu pozostávajúcou z rozmeru matice, počtu testovacích bodov, každý koľký bod sa vizualizuje pri vizualizácií celej zafarbenej plochy, zvolená hodnota `k` a prípadne úspešnosť klasifikovania bodov v percentách. Pri vizualizácií testovacích bodov sa vizualizujú vždy všetky body. Iba pri vizualizácií celej plochy sa vizualizuje každý niekoľký bod.

## 3. Testovanie

Podľa požiadaviek zadania uvádzam 4 testovacie scenáre pre rôznu hodnotu `k` pre kNN algoritmus. Pre každý test uvádzam vizualizáciu testovacích bodov a vizualizáciu plochy, ktorú tieto body ohraničujú. Spoločne pre všetky testy uvádzam zhodnotenie testovania.

## 3.1. k = 1

Vizualizácia testovacích bodov:

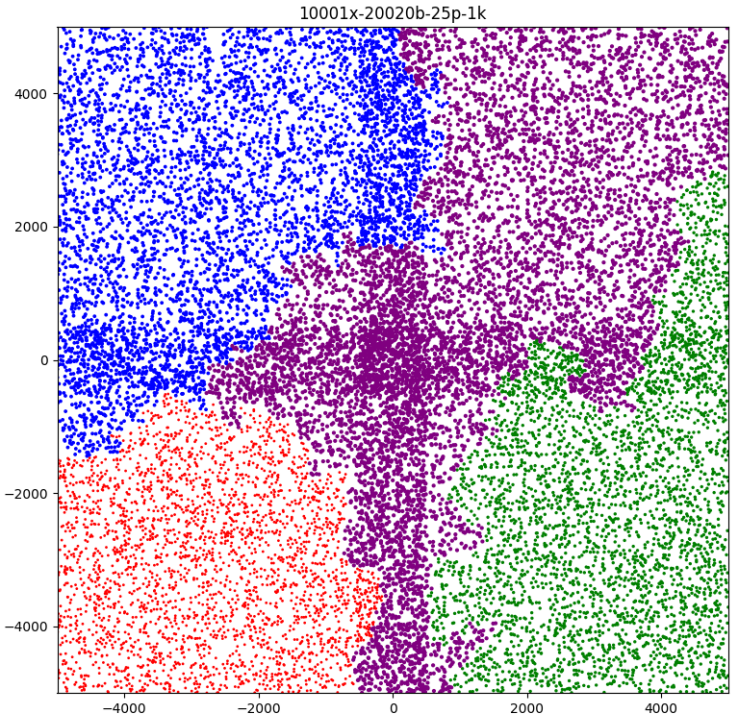


2020-12-12--18-46-32--10001x-20020b-25p-1k-Smrecek.png

Vizualizácia celej zafarbenej plochy:

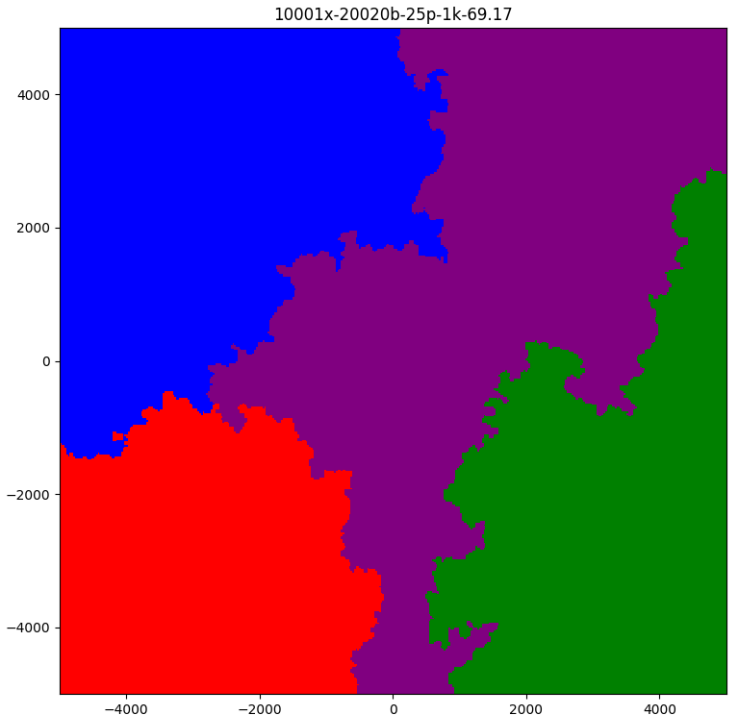


2020-12-12--18-46-57--10001x-20020b-25p-1k-69.17-Smrecek.png

## 3.2. k = 3

Vizualizácia testovacích bodov:

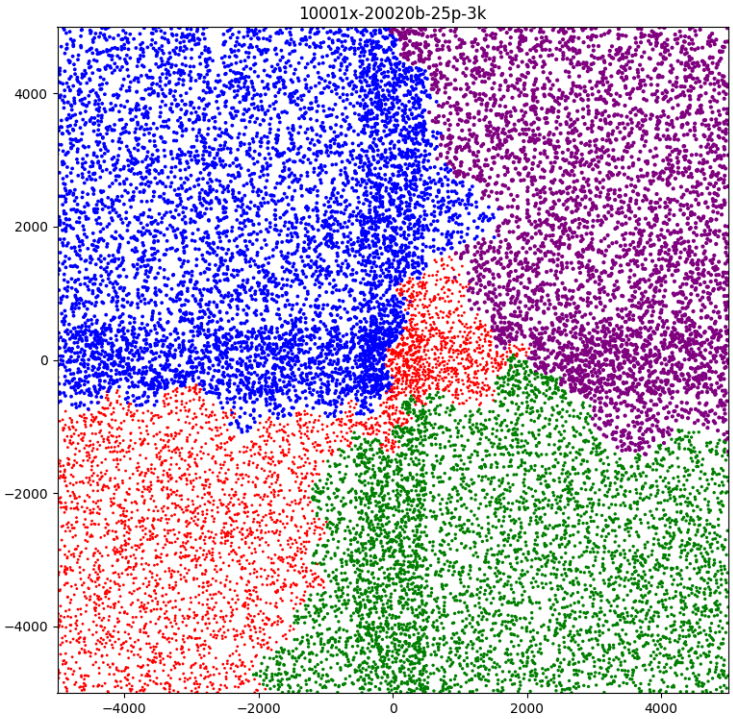


2020-12-12--18-55-52--10001x-20020b-25p-3k-Smrecek.png

Vizualizácia celej zafarbenej plochy:

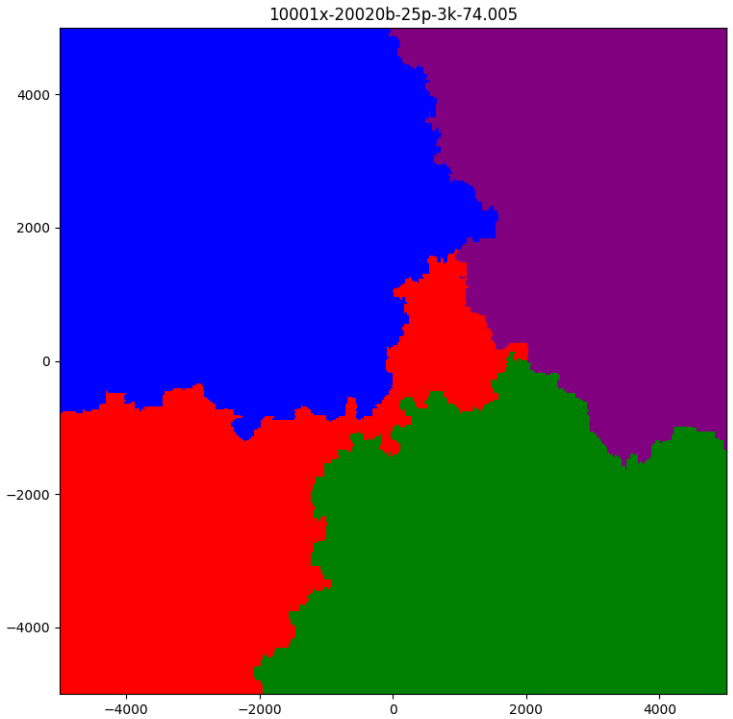


2020-12-12--18-56-20--10001x-20020b-25p-3k-74.005-Smrecek.png

## 3.3. k = 7

Vizualizácia testovacích bodov:

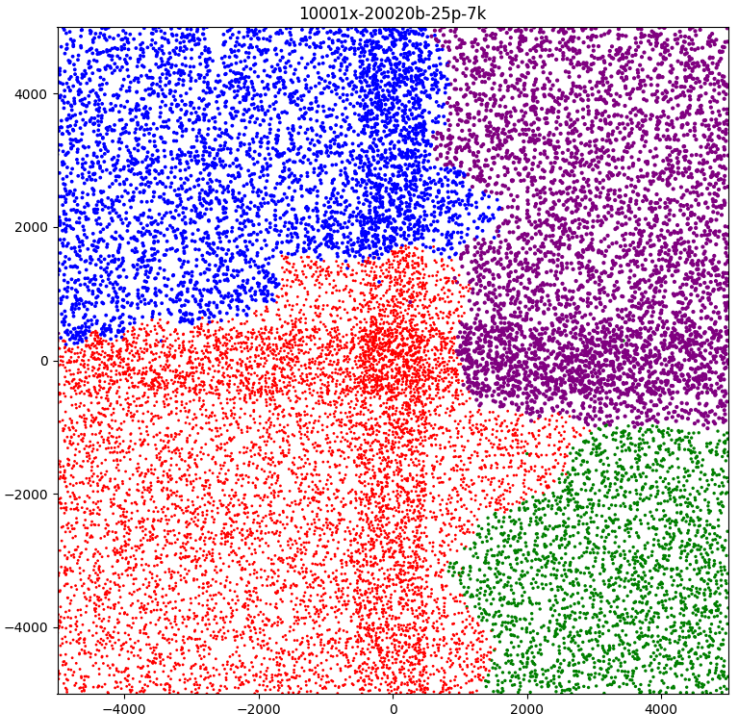


2020-12-12--19-04-44--10001x-20020b-25p-7k-Smrecek.png

Vizualizácia celej zafarbenej plochy:

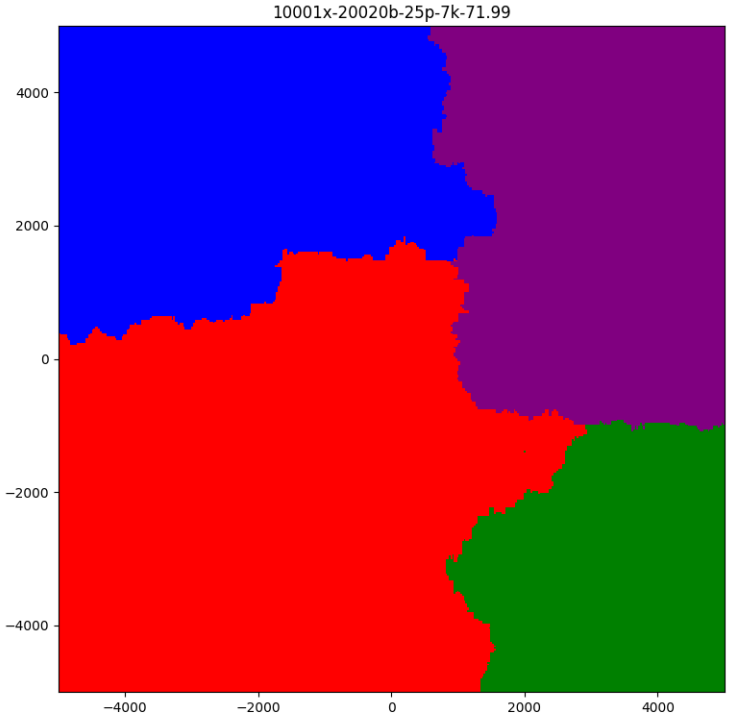


2020-12-12--19-05-13--10001x-20020b-25p-7k-71.99-Smrecek.png

## 3.4. k = 15

Vizualizácia testovacích bodov:

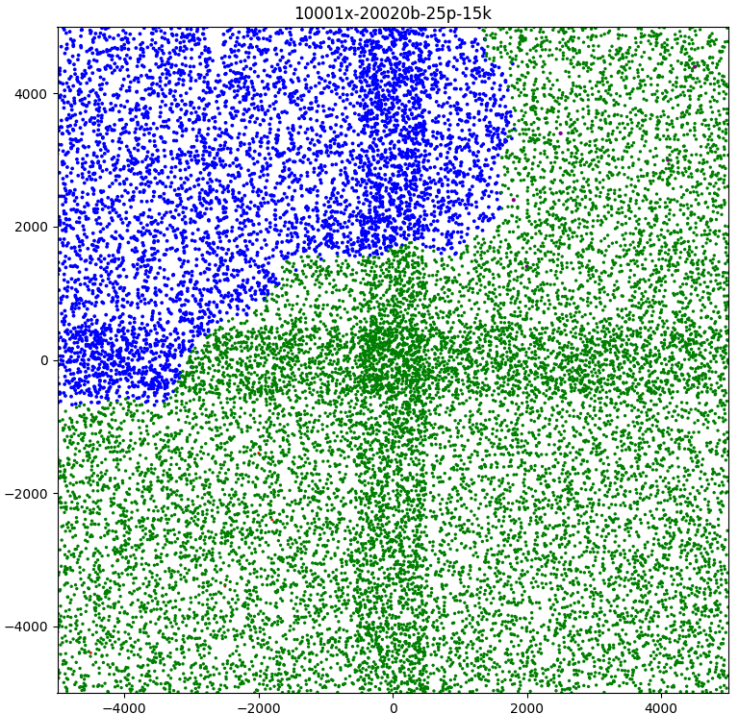


2020-12-12--19-14-21--10001x-20020b-25p-15k-Smrecek.png

Vizualizácia celej zafarbenej plochy:

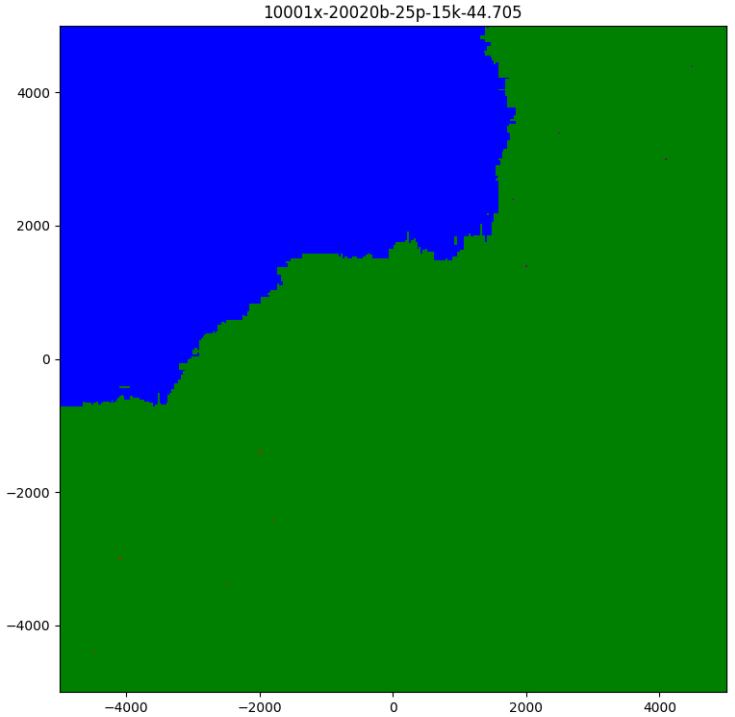


2020-12-12--19-14-53--10001x-20020b-25p-15k-44.705-Smrecek.png

## 3.5. Zhodnotenie testovania

Na obrázku nižšie sú zobrazené hranice plôch tried dané zadaním.

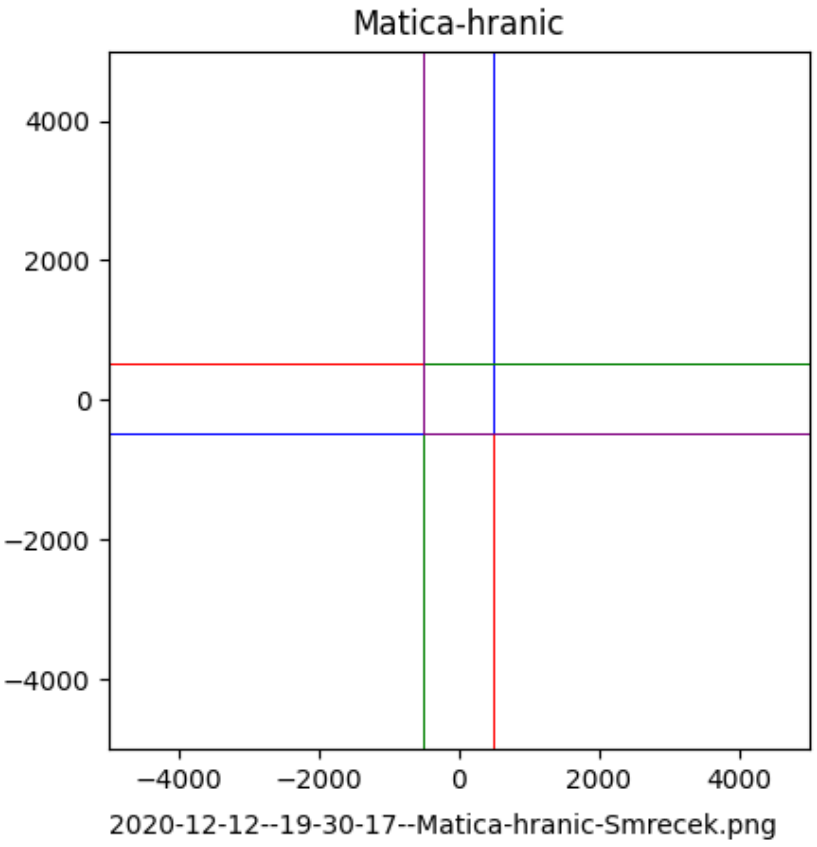


Testovanie ukázalo, že pri k = 1 mal klasifikátor úspešnosť 69,17%, pri k = 3 bola úspešnosť 74,01%, pri k = 7 bola 71,99% a pri k = 15 bola 44,71%. Percentuálne úspešnosti ukazujú, koľko bodov z 20000 bolo klasifikovaných rovnakou triedou, s akou boli vygenerované.

Môžeme vidieť, že pre k = 1 a pre k = 7 dosahuje klasifikátor podobné úspešnosti. Pri k = 3 dosahuje klasifikátor takmer trojštvrtinovú úspešnosť a pri k = 15 klasifikátor nedosahuje ani polovičnú úspešnosť.

Ako sme videli v prípade k = 1, že fialová výrazne zasiahla do plochy zelenej a červenej, bolo to spôsobené práve jednoprvkovou skupinou susedov, ktorých algoritmus zohľadňoval pri výbere farby nového bodu.

Pri k = 3 sme videli, že výsledky najviac zo všetkých pokusov korešpondovali s plochami tried určenými zadaním. Takýto výsledok sme dosiahli práve správnym zvolením hodnoty k.

Pri k = 7 sa dominantnou stala červená trieda a úspešnosť mierne klesla. Bolo to spôsobené príliš veľkou zvolenou hodnotou k.

Pri k = 15 body červenej a fialovej triedy zmizli takmer úplne. Na vizualizácií celej plochy ich nevidno vôbec. Klasifikátor klasifikoval nové body ako modré a zelené, pričom takmer úplne opomenul fialovú a červenú. Toto bolo spôsobené prehnane vysokou hodnotou k.

Z toho vyplýva, že pri klasifikácií je potrebné zvoliť také k, ktoré nie je ani príliš malé, ale také, ktoré nie je ani príliš veľké. V tomto prípade, z množiny 1, 3, 7, 15, bolo najlepšie možné zvolené k = 3.

# 4. Používateľské rozhranie a ovládanie programu

Po spustení programu si používateľ vyberie jednu z troch možností. Možnosť `a` pre spustenie testovania, možnosť `b` pre vykreslenie hraníc do mapy a uloženie takejto matice do súboru, možnosť c pre vizualizáciu matice zo súboru.

Po zvolení možnosti `a` sú od používateľa pýtané hodnoty s ktorými má program pracovať. Teda k pre kNN algoritmus, počet bodov triedy, každý koľký bod si praje používateľ vizualizovať pri vyfarbovaní celej plochy a či si používateľ želá uložiť takto vygenerovanú maticu do súboru. Ak používateľ zvolí, že si praje maticu uložiť, bude vyzvaný na zadanie cesty k priečinku, kde má byť matica uložená. Následne prebehne program ktorý robí výpisy do konzoly a vygeneruje 2 obrázky, teda vizualizáciu testovacích bodov a vizualizáciu celej zafarbenej plochy. Ak si používateľ prial uložiť takto vygenerovanú maticu, tá sa uloží na zvolenú adresu. Po vykonaní všetkých úkonov program končí. Matice uložené z možnosti `a` sú uložené kvôli niekoľkominútovému vytváraniu matíc a prípadnému opätovnému spusteniu vizualizácie bodov a vyfarbenia nad tou istou maticou. Táto opätovná vizualizácia nie je v kóde priamo implementovaná ale je možné ju vyskladať z už existujúcich funkcií.

Po zvolení možnosti `b` je používateľ vyzvaný zadať adresu na uloženie matice a program následne vygeneruje a uloží do súboru maticu s vyfarbeným ohraničením tried.

Po zvolení možnosti `c` je používateľ vyzvaný zadať cestu k uloženej matici a program následne maticu otvorí a vizualizuje funkciou `vizualizuj_maticu`. Táto funkcia je v programe používaná na vizualizáciu celých plôch, preto pre samotnú maticu bodov uloženú z možnosti `a` nedosiahne tak pekné výsledky. Táto možnosť je primárne určená pre matice získané z možnosti `b`. Grafy v časti Testovanie boli vygenerované možnosťou `a` s výnimkou grafu hraníc, ktorý ako jediný bol vygenerovaný možnosťou `c`.

# 5. Záver

V programovacom jazyku Python som implementoval klasifikáciu bodov v 2D poli. Každá funkcia programu obsahuje svoj vlastný komentár, preto komentáre k funkciám programu v tejto dokumentácií neuvádzam.

Klasifikácia prebiehala na základe kNN algoritmu pre plochu o veľkosti 10001 x 10001. Pôvodných bodov bolo 20, ku ktorým som oklasifikoval a pridal ďalších 20000 bodov.

Následne som vizualizoval týchto 20020 vložených bodov na grafe a vizualizoval som aj plochu, ktorú tieto body ohraničujú.

Otestoval som program pre hodnoty k rovné 1, 3, 7 a 15 a zhodnotil výstupy. Najlepšie výsledku dosahoval program pre k = 3.

Z výsledkov testovania vyplýva, že pri klasifikácií je potrebné zvoliť také k, ktoré nie je ani príliš malé, ale také, ktoré nie je ani príliš veľké.